



Yapay Zeka Destekli Mantar Zehirlilik Tespit Sistemi

AI-Powered Mushroom Toxicity Classification — Binary Classification Project

Hazırlayan	Gürcan Karadağ
Proje Türü	Binary Classification (0 = Yenilebilir, 1 = Zehirli)
Veri Seti	UCI Mushroom Dataset (Kaggle)
Kullanılan Teknoloji	Python, Scikit-learn, Streamlit
Tarih	Nisan 2025

1. Proje Özeti

Bu projede, mantarların morfolojik özelliklerine (şapka şekli, renk, koku, solungaç yapısı vb.) dayalı olarak bir mantarın yenilebilir mi yoksa zehirli mi olduğunu tespit eden bir Yapay Zeka sistemi geliştirilecektir. Problem, doğası itibarıyla bir ikili sınıflandırma (binary classification) görevidir: çıktı 0 (edible — yenilebilir) veya 1 (poisonous — zehirli) olacaktır.

Sistem; veri ön işleme, özellik mühendisliği, model eğitimi ve değerlendirme aşamalarından oluşacak; ardından kullanıcının mantar özelliklerini seçerek anlık tahmin alabildiği sade bir Streamlit web arayüzüyle son kullanıcıya sunulacaktır. Proje, yüksek doğruluk oranı kadar yanlış negatif (zehirli mantarı yenilebilir gösterme) hatasını minimize etmeyi öncelikli hedef olarak benimseyecektir; zira bu tür bir hata gerçek dünyada can kayıplarına yol açabilir.

2. Problem Tanımı ve Motivasyon

Dünya genelinde binlerce mantar türü bulunmakta olup bunların önemli bir kısmı zehirlidir. Görsel benzerlikler nedeniyle uzman olmayan bireylerin yenilebilir ve zehirli mantarları ayırt etmesi son derece güçtür. Yanlış mantar tüketimi ciddi organ hasarına, hatta ölüme yol açabilmektedir.

Makine öğrenmesi yöntemleriyle oluşturulacak bir sınıflandırma modeli; renk, koku, şapka yapısı gibi gözlemlenebilir özelliklerden yola çıkarak zehirliliği hızlı ve güvenilir biçimde tahmin edebilir. Bu proje, hem gerçek dünya faydasını hem de ikili sınıflandırma algoritmalarının pratik uygulamasını aynı anda sergileme imkânı sunmaktadır.

3. Kullanılan Veri Seti

UCI Mushroom Dataset

Bu proje için UCI Machine Learning Repository'den alınan ve Kaggle üzerinde de yayımlanan Mushroom Classification veri seti kullanılacaktır.

- Kaynak: <https://www.kaggle.com/datasets/uciml/mushroom-classification>
- Örnek Sayısı: 8.124 mantar kaydı
- Etiket: class sütunu — 'p' (poisonous / zehirli) ve 'e' (edible / yenilebilir)
- Sınıf Dağılımı: 4.208 yenilebilir (%51,8) — 3.916 zehirli (%48,2) → dengeli veri seti
- Özellik Sayısı: 22 kategorik özellik

Veri setindeki başlıca özellikler şunlardır:

- cap-shape: Şapka şekli (düz, çan, girintili vb.)
- cap-color: Şapka rengi (kahverengi, gri, beyaz, sarı vb.)
- odor: Koku (anise, foul, none, fishy, spicy vb.) — en ayırt edici özellik
- gill-color: Solungaç rengi
- ring-type: Halka tipi
- spore-print-color: Spor baskısı rengi
- habitat: Doğal yaşam alanı (orman, çayır, kentsel vb.)

4. Metodoloji

4.1 Veri Ön İşleme

- Eksik değer analizi ve '?' ile işaretli kayıtların yönetimi (stalk-root sütunu)
- Label Encoding / One-Hot Encoding ile kategorik özelliklerin sayısallaştırılması
- Hedef değişken dönüşümü: 'p' → 1 (zehirli), 'e' → 0 (yenilebilir)
- Eğitim/test ayrımı: %80 eğitim, %20 test (stratified split)

4.2 Özellik Mühendisliği

- Özellik önem analizi (Feature Importance) ile en ayırt edici özelliklerin belirlenmesi
- Korelasyon matrisi ile gereksiz/tekrarlayan özelliklerin tespiti
- Seçilen özelliklerin model girişine hazırlanması

4.3 Model Geliştirme

Aşağıdaki modeller eğitilecek ve performansları karşılaştırılacaktır:

- Logistic Regression — temel referans model (baseline)
- Random Forest Classifier — güçlü, yorumlanabilir, özellik önemini verir
- XGBoost / Gradient Boosting — yüksek performans, dengesiz verilerde güçlü
- Decision Tree — görselleştirilebilir, yorumu kolay

Modeller arasında en düşük False Negative (FN) oranını üreten model nihai sistem için seçilecektir. Zehirli bir mantarı yenilebilir olarak etiketlemek (FN) hatalı türlere göre çok daha kritik bir hata olduğundan Recall (Sensitivity) metriği önceliklendirilecektir.

4.4 Model Değerlendirme

- Accuracy — genel doğruluk
- Precision — zehirli diye etiketlenenlerin gerçekten zehirli olma oranı
- Recall (Sensitivity) — gerçek zehirli mantarların yakalanma oranı [öncelikli metrik]
- F1-Score — Precision ve Recall dengesi
- ROC-AUC — sınıflandırıcı performansının eşik bağımsız ölçümü
- Confusion Matrix görselleştirmesi

4.5 Web Arayüzü (Streamlit)

Kullanıcıların teknik bilgiye ihtiyaç duymadan sistemi kullanabilmesi için Streamlit ile sade ve işlevsel bir web arayüzü geliştirilecektir. Arayüz şu unsurları içerecektir:

- Dropdown menüler aracılığıyla mantar özelliklerinin seçilmesi (22 özellik)
- 'Analiz Et' butonu ile anlık tahmin alınması
- Sonucun renkli ve açıklayıcı biçimde gösterimi (yeşil: yenilebilir / kırmızı: zehirli)
- Tahmin güven skoru (probability output) gösterimi
- En etkili özelliklerin bar grafiğiyle görselleştirilmesi

5. Beklenen Proje Dosya Yapısı

Dosya / Klasör	Açıklama
mushroom_classifier/	Ana proje klasörü
├─ data/mushrooms.csv	Ham veri seti
├─ notebooks/EDA.ipynb	Keşifsel veri analizi
├─ notebooks/model_training.ipynb	Model eğitimi ve değerlendirme
├─ src/preprocessing.py	Veri ön işleme modülü
├─ src/model.py	Model eğitimi ve kaydetme
├─ src/predict.py	Tahmin fonksiyonları
├─ app/streamlit_app.py	Web arayüzü
├─ models/rf_model.pkl	Kaydedilmiş eğitilmiş model
├─ requirements.txt	Bağımlılık listesi
└─ README.md	Proje dokümantasyonu

6. Teknik Yığın (Tech Stack)

Kategori	Araçlar / Kütüphaneler
Dil	Python 3.10+
Veri İşleme	Pandas, NumPy
Makine Öğrenmesi	Scikit-learn, XGBoost
Görselleştirme	Matplotlib, Seaborn, Plotly
Web Arayüzü	Streamlit
Model Kaydetme	Joblib / Pickle
Versiyon Kontrol	Git / GitHub

Ortam Yönetimi

pip + requirements.txt

7. Proje Planı ve Kilometre Taşları

Aşama	Görev	Durum
1	Veri seti temini ve EDA (Keşifsel Veri Analizi)	Planlanan
2	Veri ön işleme ve özellik mühendisliği	Planlanan
3	Model eğitimi ve hiperparametre optimizasyonu	Planlanan
4	Model değerlendirme ve karşılaştırma	Planlanan
5	Streamlit arayüzü geliştirme	Planlanan
6	README.md ve dokümantasyon	Planlanan
7	GitHub'a yükleme ve demo video/sunum	Planlanan

8. Beklenen Çıktılar

UCI Mushroom veri setinin dengeli yapısı ve güçlü ayırt edici özellikleri (özellikle koku) göz önüne alındığında, Random Forest ve XGBoost modellerinin %99 üzerinde accuracy ve tam anlamıyla sıfıra yakın False Negative (FN) oranı üretmesi beklenmektedir.

- Yüksek Recall ($\geq$ %99) — zehirli hiçbir mantar kaçırılmamalı
- Yüksek F1-Score — precision ve recall dengesi
- Kullanıcı dostu Streamlit arayüzü ile gerçek zamanlı tahmin
- Özellik önem grafiği — hangi özelliğin kararı ne kadar etkilediği
- Açık kaynak GitHub repo'su ve kapsamlı README.md

9. Değerlendirme Kriterleriyle Uyum

Kriter	Ağırlık	Planlanan Yaklaşım
Fonksiyonellik	%40	Veri yükleme, ön işleme, model tahmini ve Streamlit arayüzü tam entegre
Kod Kalitesi	%20	Docstring'li, modüler fonksiyonlar; preprocessing sınıfı; optimize pipeline
Arayüz	%20	Sade Streamlit UI; renkli sonuç gösterimi; güven skoru ve grafik

Dokümantasyon	%10	Detaylı README.md; kurulum ve kullanım talimatları; teknik açıklamalar
Teslim Edilenler	%10	Ekran görüntüsü + demo video veya proje raporu

10. Kaynaklar

- UCI Mushroom Dataset: <https://www.kaggle.com/datasets/uciml/mushroom-classification>
- Scikit-learn Dokümantasyonu: <https://scikit-learn.org>
- Streamlit Dokümantasyonu: <https://streamlit.io>
- XGBoost Dokümantasyonu: <https://xgboost.readthedocs.io>
- GitHub Repo: (Proje tesliminde eklenecektir)